

# الگوریتم بهینه سازی تقلیدگری اجتماعی

چکیده:

رشد پیچیدگی مسائل دنیای واقعی زمینه ای برای جستجوی روشهای کارآمد حل مسئله در حوزه علوم کامپیوتر ایجاد نموده است. روشهای فرامکاشفه ای مبتنی بر محاسبات تکاملی و هوش ازدحامی نمونه های از تکنیکهای الهام گرفته از طبیعت هستند. این مقاله با الهام از رفتار مقلدانه، الگوریتم جدید بهینه سازی تقلیدگری اجتماعی (SMO) برای حل مسائل بهینه سازی را ارائه می دهد. الگوریتم پیشنهادی با ۲۳ تابع شناخته شده آزمون ارزیابی شده است. نتایج بدست آمده از الگوریتم با ۱۴ الگوریتم بهینه سازی شناخته شده

Whale optimization algorithm (WOA), Grasshopper optimization algorithm (GOA), Particle Swarm Optimization (PSO), Stochastic fractal search (SFS), Grey Wolf Optimizer (GWO), Optics Inspired Optimization (OIO), League Championship Algorithm (LCA), Wind Driven Optimization (WDO), Harmony search (HS), Firefly Algorithm (FA), Artificial Bee Colony (ABC), Biogeography Based Optimization (BBO), Bat Algorithm (BA), Teaching Learning Based Optimization (TLBO)

مقایسه شده است. نتایج حاصله توانایی بالاتر الگوریتم SMO در حل مسائل با ابعاد زیاد متغیرهای تصمیم را نشان می دهد. علاوه بر این SMO برای حل دو مسئله بهینه سازی طراحی مهندسی کلاسیک استفاده شده است. سه ویژگی مهم SMO سادگی پیاده سازی، حل مسائل بهینه سازی با کمترین جمعیت و عدم نیاز به پارامتر کنترلی هستند.

کلمات کلیدی: فرامکاشفه ای، بهینه سازی، هوش ازدحامی، بهینه سازی تقلیدگری اجتماعی

## ۱- مقدمه

بهینه سازی فرآیندی برای بدست آوردن مقادیر بهینه پارامترهای یک مسئله با تمام مقادیر احتمالی برای افزایش یا کاهش خروجی در نظر گرفته می شود. مسائل پیچیده ای مانند زمانبندی، خوشه بندی داده ها، پردازش تصویر، تنظیم شبکه های عصبی در حوزه مسائل بهینه سازی قرار می گیرند. برای حل اینگونه مسائل، دوراهاکار روشهای بهینه سازی کلاسیک و روشهای فرامکاشفه ای وجود دارد. بحث های فراوانی در خصوص عدم دست یابی روشهای کلاسیک در زمان معقول به جواب بهینه صورت گرفته است. ازطرفی روشهای فرامکاشفه ای بدلیل سادگی، انعطاف پذیری، مکانیزم بدون مشتق و اجتناب از بهینگی محلی به طور چشمگیری در حل مسائل بهینه سازی رایج شده اند [۱].

روشهای فرامکاشفه ای را می توان به دو دسته تک راه حلی و چند راه حلی تقسیم نمود. در دسته اول فرآیند جستجو با یک راه حل شروع می شود. این راه حل کاندید یکتا در تکرار های بعدی بهبود می یابد. در مقابل روشهای فرامکاشفه ای چند راه حلی، بهینه سازی را با استفاده از مجموعه ای از راه حل های اولیه تصادفی (جمعیت) انجام می دهند. جمعیت در تکرارهای بعدی بهبود می یابد. بر اساس تحقیقات انجام شده روشهای مبتنی بر چند راه حل نسبت به روشهای مبتنی بر یک راه حل محبوبتر هستند [۲].

روشهای مبتنی بر چند راه حل هنگام بهینه سازی بدلیل تعداد زیاد راه حل تصادفی اولیه از بهینه محلی اجتناب می کنند. این روشها بخش بزرگتری از فضای جستجو را بررسی می کنند بنابراین احتمال پیدا کردن جواب بهینه مطلوب بالاتر است. اطلاعات در مورد فضای جستجو میتواند بین چندین راه حل مبادله شود. که باعث همگرایی سریعتر به سمت بهینه مطلوب

می شود. روشهای مبتنی بر چند راه حل نیازمند ارزیابی تابع بهینگی بیشتری نسبت به روشهای مبتنی بر یک راه حل هستند. الگوریتم های مبتنی بر یک راه حل مانند تپه نوردی [۳] و تبرید شبیه سازی شده [۴] هر دو ایده مشابهی را دنبال می کنند. اما اجتناب از بهینه محلی در SA بهتر است. دسته ای از روش های فرامکاشفه ای چند راه حلی روشهایی هستند که رفتار اجتماعی و هوش گروهی افراد، حیوانات، گله ها، تیم ها یا هر دسته از مخلوقات را تقلید می کنند. حرکت ارگانیسمها به فرم یک گرو مانند پرواز دسته جمعی پرندگان، شکار گروهی یا مدرسه ماهی ها ایده بوجود آمدن ازدحام ذرات بوده است. گروه بوسیله ازدحام ذرات بازنمایی می شود و ازدحام ذرات از موقعیت آنها در فضای جستجو برای نمایش راه های ممکن مسئله بهینه سازی استفاده می نماید. PSO با دست کاری حرکت این ذرات بهینه سازی را انجام می دهد. بهینه سازی ازدحام ذرات [۵] که در بین دانشمندان علوم مختلف به عنوان یک روش بهینه سازی کارآمد شناخته شده است در این دسته قرار می گیرد. الگوریتم دیگر این دسته که توسط Dorigo معرفی شده الگوریتم بهینه سازی کلونی مورچه (ACO) [۶] است. این الگوریتم از رفتار اجتماعی مورچه ها در یک کلونی الهام گرفته شده است. تقلید هوش اجتماعی مورچه ها در یافتن کوتاهترین مسیر بین آشیانه و منبع غذا پایه الهام الگوریتم کلونی مورچگان است. در این روش فرا ابتکاری راه حل های ممکن برای حل مسله بهینه سازی به وسیله مسیرهای بین کلونی و منبع غذا بازنمایی می شوند. مورچه ها از طریق فرومون با یکدیگر ارتباط برقرار کرده و دیگران را از محل منبع غذا آگاه می سازند. هنگامیکه مورچه ای غذایی را می یابد بر اساس کیفیت منبع غذا مسیر را با استفاده از فرومون علامت گذاری می نماید. هرچه این مسیر توسط سایر مورچه ها انتخاب شود غلظت فرومون آن بیشتر می شود. افزایش میزان فرومون در یک مسیر نشان دهنده مسیر کوتاهتر و منبع با کیفیت تر غذا است.

یکی از گسترده ترین ارگانیسم های مطالعه شده در هوش ازدحامی زنبور عسل است [۷]. ازدواج در بهینه سازی زنبور عسل در [۸] ارائه شده است. در این الگوریتم پرواز جفتگیری زنبور ملکه بعنوان گذر در فضای جستجو بازنمایی می شود. احتمال جفت گیری با سرعت و انرژی ملکه و میزان بهینگی زنبور عسل نر تعیین می شود. بهینه سازی کلونی زنبور عسل مصنوعی توسط karabaga و همکارش پیشنهاد شد [۹]. Artificial Bee Colony Algorithm (ABC) زنبورهای درون کندو را به سه دسته طبقه بندی می نماید. زنبور های پیشاهنگ که بدون راهنما و به صورت تصادفی پرواز می نمایند، زنبور های کارگر که موقعیت همسایگان خود را جستجو نموده و زنبور های ناظر که از بهینگی جمعیت برای انتخاب راه حل راهنما برای بهره برداری استفاده می نمایند.

الگوریتم، توازن بین مراحل اکتشاف و بهره برداری را با استفاده از زنبور های پیشاهنگ و کارگر برای جستجوی محلی و زنبورهای ناظر برای جستجوی سراسری برقرار می نماید. ضعف معادلات بهره وری نسبت به اکتشافات در الگوریتم ABC ایده ارائه Modified Gbest Artificial Bee Colony Algorithm [۱۰] بوده است.

Ghose و Krishnanand بهینه سازی ازدحام کرم شب تاب [۱۱] را براساس رفتار کرم شب تاب ارائه نمودند. yang و همکارانش [۱۲] با الگوی حرکت همکارانه الگوریتمی جدید بر پایه تکنیک کرم شب تاب ارائه نموده اند. الگوریتم دیگری که بر پایه زندگی گرم شب تاب توسعه یافته الگوریتم تغییر یافته کرم شب تاب است [۱۳] در این الگوریتم حرکت تصادفی کرم شب تاب پرنور تر بوسیله تولید جهت های تصادفی به جای تعیین بهترین جهتی که نور در آن افزایش می یابد اصلاح شده است. الگوریتم های [۱۴، ۱۵] از رفتار جفتگیری و استراتژی تغذیه عنکبوت اجتماعی برای حل مسائل بهینه سازی الهام گرفته اند. الهام از فرآیند مربیگری تیم در مسابقه های لیگ والیبال مبنای ارائه الگوریتم VPL بوده است [۱۶].

Soccer is a team game in which players try to find the best position and attaining a goal under the supervision of a coach. Soccer game metaheuristic algorithm simulates behavior of players [17]. Importance of this method is in modeling human's intelligence. Gong employs adaptive learning based on contradiction to improve fireworks algorithm [18]. Wung et.al. have proposed a metaheuristic algorithm called monarch butterfly optimization algorithm based on migration of the monarch butterfly [19]. A metaheuristic algorithm which has an optimization sine cosine algorithm based on population is proposed in [20]. In this algorithm, multiple initial random candidate solutions are created. Then a mathematical model based on sine and cosine function is used to move candidate solution towards optimal solution. Cheng et.al. have proposed an algorithm to solve engineering problems inspired by symbiosis organisms (SOS). In this paper, interplay strategies of adaptive symbiosis is modeled using organisms for survival [21]. Inspired by strategy of humpback whale hunting is the idea proposed in whale optimization algorithm [22]. Ability of Bats to manipulate frequency and wavelength of audio waves emitted while hunting is the idea of proposing dynamic virtual bats [23]. In this algorithm, search is based on developed role to enhance bat algorithm. Combining Harmonic search algorithm with variable population and quantum principles is proposed in [24]. Authors have employed the proposed method to solve vehicles routing problem. Other swarm intelligence techniques in the literature are: Slap Swarm Algorithm (SSA) [25], Grasshopper Optimization Algorithm (GOA) [26], the ant lion optimizer (ALO) [27], and Dolphin Echolocation (DE) [28]. In order to become familiar with evolutionary computations and their applications, it is recommended to study [29].

الگوریتم های هوش ازدحامی اطلاعات مربوط به فضای جستجو را در حین یک دوره تکرار حفظ می کنند. این الگوریتم ها اغلب از حافظه برای ذخیره بهترین راه حل بدست آمده در هر مرحله استفاده می نمایند. همچنین این الگوریتم ها پارمتر های کمتری برای تنظیم دارند از سوی دیگر بدلیل عملگرهای کمتر برای مدلسازی رفتار طبیعی و جستجوی تصادفی پیاده سازی آنها آسانتر است..

علیرغم تعداد زیاد الگوریتم های فرا ابتکاری ارائه شده این سوال مطرح می شود که چرا نیازمند روشهای بهینه هستیم. این سوال توسط قضیه نهار غیررایگان (NFL) [۳۰] پاسخ داده می شود. این قضیه به صورت منطقی ثابت می کند هیچ روش فرا مکاشفه ای وجود ندارد که برای تمام مسائل بهینه سازی مناسب باشد. در نتیجه به طور مداوم روشهای موجود ارتقاء می یابند یا روشهای فرا ابتکاری جدیدی پیشنهاد می شوند. تحقیقات انجام شده در حوزه روشهای فرا ابتکاری در سه دسته بهبود روشهای موجود، ترکیب آنها و ارائه الگوریتم های جدید قرار می گیرند. این مقاله روش فرا ابتکاری مبتنی بر چند راه حل با الهام از رفتار های تقلیدی پیشنهاد می دهد. روش پیشنهادی با کاهش تعداد راه حل (جمعیت) توانسته است بر مهمترین ایراد این دسته از الگوریتم ها (تعداد زیاد ارزیابی تابع بهینگی) غلبه نماید. ادامه مقاله به این صورت سازماندهی شده است در بخش دوم تعاریف تقلیدگری از دیدگاه تاریخی و علمی مطرح می شود. بخش سوم الگوریتم بهینه سازی تقلید اجتماعی را معرفی می کند. بخش چهارم آزمایشات و نتایج مقایسه SMO با سایر روشهای شناخته شده را پوشش می دهد. در نهایت مقاله در بخش ۵ خلاصه سازی می شود.

## ۲- تقلیدگری اجتماعی – دیدگاه تاریخی و علمی

ریشه تقلیدگری یا شبیه ساختن روحیه و رفتار خود به دیگران را می توان در انسان های اولیه جستوجو کرد. انسان ها از همانندسازی به عنوان نوعی علائم عمومی استفاده کرده اند. بشر برای زنده ماندن و تکامل باید چیزهای زیادی ازجمله رفتارهای اجتماعی پذیرفته شده را یاد می گرفت و ابداع می کرد. افراد قابل احترام تر، قوی تر و باهوش تری در جامعه انسانی وجود داشتند که از جایگاه اجتماعی بالاتری برخوردار بودند و دیگران باید برای نشان دادن احترامشان به این افراد، الگوهای رفتاری خاصی را درخود ایجاد می کردند. برای مثال، اگر این افراد قابل احترام، از یک دستبند به عنوان شیئی تزئینی استفاده

می‌کردند، سایر افراد گروه آن را یک رفتار مرسوم تلقی می‌کردند و دست کردن چنان دستبندی را برای خود یک باید می‌دانستند.

حالت‌های عاطفی کسانی که با آنها روبه‌رو می‌شویم، احساسات ما را تحت تاثیر قرار می‌دهد. احساسات و روحیاتی مانند اضطراب و شادی می‌توانند از فردی به فرد دیگر منتقل شوند. این تقلید عاطفی به صورت خود به خود و ناخودآگاه رخ می‌دهد، اما علم چگونه این هماهنگ‌سازی در ارتباطات را توضیح می‌دهد؟ همه چیز به یک سیستم نورونی در مغز انسان بازمی‌گردد. نورون‌های خاصی، مسئول تشخیص چهره‌ها و درک حالت‌های چهره هستند و تفسیری که این نورون‌ها از حالات عاطفی طرف مقابل می‌کنند باعث می‌شود شما در ارتباط با فرد مقابل، ابروهایتان را درهم بکشید یا لبخند به چهره‌تان بنشانید. این نورون‌ها که مانند پلی بین مغزها عمل می‌کنند به شکل شگفت‌انگیزی قدرت تقلید غیرارادی اعمال مشاهده شده را به عهده دارند و هم هنگام عملکرد خود فرد و هم هنگام مشاهده اعمال حسی و حرکتی در افراد دیگر، از خود فعالیت نشان می‌دهند. به عبارت دیگر، ما از نظر زیستی برای تقلید از احساساتی که دیگران از طریق حالت‌های صورت و حرکات بدنی به نمایش می‌گذارند، برنامه‌نویسی شده‌ایم و با این کار، احساسات درونی دیگران را برای خودمان نیز اتخاذ می‌کنیم. به طور خلاصه می‌توان گفت در طول تاریخ افراد در تلاش هستند تا با تقلید رفتار، گفتار، پوشش و سایر ویژگی‌های افراد مشهور خود را مشابه آنان نمایند. به عبارت دیگر با تقلیدگری اجتماعی در تلاش هستیم به سوی نقطه بهتر حرکت نماییم.

## ۲-۱ سیستم نرون های آینه ای

اواخر قرن بیستم میلادی، ریزولاتی، عصب‌شناس ایتالیایی و همکارانش از دانشگاه پارما، وقتی روی میمون‌ها کار می‌کردند، مشاهده کردند وقتی یک میمون خودش موز می‌خورد یا خوردن موز توسط میمون یا انسان دیگری را مشاهده می‌کند، سلول‌های عصبی مشابهی در مغز او فعال می‌شوند. از آنجا که این سلول‌های عصبی اقدامات دیگران را به طور آینه‌ای در مغز ما بازتاب می‌دهند، دانشمندان آنها را نورون‌های آینه‌ای [۳۱] نامگذاری کردند. از آن زمان تاکنون پژوهش‌های بسیاری درباره این سیستم عصبی در انسان و سایر حیوانات انجام شده است. اکنون ما می‌دانیم این سیستم عصبی در انسان بسیار پیشرفته‌تر از میمون‌هاست. مشاهدات بعدی نشان داد ۱۰ درصد نورون‌های قشر اینفریور فرانتال (Inferior Frontal) و اینفریور پرایتال (Inferior Parietal) ویژگی‌های آینه‌ای دارند و پاسخ مشابهی به حرکات و رفتارهای مشاهده شده نشان می‌دهند. این نورون‌ها به ما امکان می‌دهند صرفاً با مشاهده رفتار دیگران، یاد بگیریم، مقاصد افراد را بفهمیم و پیام‌های بدنی و حالت‌های چهره آنها را متوجه شویم. خنده یا اخم یک فرد سبب خنده و اخم فرد دیگری می‌شود و چنین چیزی می‌تواند ایجاد همدلی میان افراد را در پی داشته باشد. در واقع سیستم نورون‌های آینه‌ای یک مکانیسم عصبی برای سرایت و گسترش احساسات در گروه‌های انسانی ایجاد می‌کند. به عبارت دیگر ما برای فهمیدن، برقراری ارتباط و صمیمی شدن با دیگران عصب‌کشی شده‌ایم و نمی‌توانیم این مدارها را خاموش کنیم.

راماچاندران (Ramachandran)، از مشهورترین عصب‌شناسان معاصر می‌گوید: پیش‌بینی من این است سیستم نورون‌های آینه‌ای در روان‌شناسی همان کاری را خواهد کرد که دی‌ان‌ای برای زیست‌شناسی انجام می‌دهد [۳۲].

## ۳- الگوریتم تقلیدگری اجتماعی

الگوریتم پیشنهادی تقلیدگری اجتماعی از رفتار مقلدانه افراد در اجتماع الهام گرفته شده است. در رفتار تقلیدگری هر فرد سعی دارد با تقلید رفتارهای افراد مشهور خود را هر چه بیشتر به آنها مشابه نماید. بر همین اساس در مسائل بهینه سازی هر راه حل با تقلید پارامترهای راه حل بهینه می تواند به سمت پاسخ بهینه سراسری مسئله حرکت نماید.

در مسائل بهینه سازی می توانیم با مدل سازی رفتار تقلید گرایانه، به صورت تصادفی فضای پاسخها را جستجو نماییم. هر راه حل با مقایسه مقدار بهینگی خود با مقدار بهینه سراسری بدست آمده تا تکرار اخیر، مقدار تفاوت خود با مقدار بهینه سراسری را تعیین می نماید. سپس با اعمال میزان تفاوت به پارامترهای مسئله در واقع فضای پاسخها را به صورت تصادفی جستجو می نماید.

در الگوریتم تقلیدگری اجتماعی از عبارت *Follower* برای بازنمایی مفهوم جمعیت استفاده میشود. علاوه بر آن عبارت های "لیدر" و "تعداد تقلید" به ترتیب نشان دهنده بهترین مقدار بهینگی سراسری و تعداد تکرار جاری هستند. هر *Follower* یک راه حل مسئله را بازنمایی می کند. مثلاً  $Follower_i$  امین عضو جمعیت را بازنمایی می کند. در ادامه هریک از مراحل الگوریتم پیشنهادی تشریح می شوند.

### ۳-۱ مقدار دهی اولیه

همانند سایر الگوریتم های بهینه سازی، SMO با مقدار دهی اولیه *Follower* ها که بازنمایی مجموعه راه حل های اولیه هستند شروع می شود. تعداد *Follower* با متغیر  $Pop\_Size$  تعیین می شود که مشخص کننده اندازه جمعیت است. هر *Follower* بوسیله برداری با ابعاد  $1 \times N$  نمایش داده می شود که  $N$  برابر با تعداد متغیرهای تصمیم مسئله است. به هر یک از عناصر این بردار اعداد تصادفی بین حد پائین و حد بالای هر متغیر تصمیم با استفاده از رابطه (۱) نسبت داده می شود.

$$Follower_i(1, j) = lb_j + Rand() * (ub_j - lb_j) \quad j = 1, 2, \dots, N \quad (1)$$

$lb_j$  و  $ub_j$  به ترتیب حد پایین و حد بالای متغیر  $j$  ام هستند. تابع  $Rand()$  عددی تصادفی با توزیع یکنواخت بین صفر و یک تولید می کند. برای ذخیره مجموعه تمام راه حل ها از ماتریس *Social* با ابعاد  $Pop\_Size \times M$  استفاده می نماییم. تعداد سطرهای این ماتریس برابر است با تعداد جمعیت و تعداد ستونهای آن برابر است با تعداد متغیرهای تصمیم به علاوه یک  $N+1$  که  $N$  ستون برای ذخیره مقادیر متغیرهای تصمیم وستون آخر برای ذخیره مقدار بهینگی هر *Follower* بکار گرفته می شود. در این مرحله هر راه حل (*Follower*) با استفاده از تابع بهینگی ارزیابی شده و مقدار بهینگی آن در ستون آخر ماتریس *Social* ذخیره می شود در نهایت *Follower* با بهترین مقدار بهینگی به عنوان *Leader* انتخاب خواهد شد.

### ۳-۲ تقلید

در این مرحله از الگوریتم هریک از *Follower* ها تفاوت خود تا *Leader* بدست آمده از مرحله قبل را با استفاده رابطه ۲ محاسبه می نماید.

$$Difference = (Leader - Fitness\ Of\ (Follower_i)) / Fitness\ Of\ (Follower_i) \quad (2)$$

در صورتیکه مقدار *Difference* برابر صفر باشد با استفاده از تابع  $Rand()$  مقدار تصادفی در بازه  $[0,1]$  به آن اختصاص می یابد. در گام بعدی مقادیر جدید متغیرهای تصمیم  $Follower_i$  با استفاده از رابطه ۳ محاسبه می گردد.

$$Follower_i = Follower_i + Difference \times Follower_i \quad (3)$$

اکنون مقدار بهینگی هر *Follower* با استفاده از تابع بهینگی ارزیابی و مقدار جدید آن در صورت بهبود در ماتریس *Social* جایگزین مقدار قبلی می گردد. پس از محاسبه مقادیر تمامی *Follower* ها بهترین بهینگی انتخاب و مقدار *Leader* بروز رسانی می شود.

### ۳-۳ شرط خاتمه

فاز تقلید تا منطبق شدن با شرط خاتمه ادامه می یابد. شرط خاتمه می تواند بوسیله حداکثر تعداد تکرار، حداکثر زمان استفاده از *cpu*، رسیدن به نرخ خطای مشخص، حداکثر تعداد تکرار بدون تغییر در مقدار بهترین بهینگی یا هر شرط مناسب با مسئله تعیین شود. پس از این مرحله، الگوریتم راه حل با بهترین بهینگی یافته شده را نمایش می دهد. مراحل سه گانه بالا الگوریتم کامل SMO را تشکیل می دهند. شبه کد آنرا می توانید در Algorithm1 بیابید. همانطور که از شبه کد مشخص است SMO نیازمند هیچ پارامتر اولیه نیست و این ویژگی روش پیشنهادی را از تنظیم پارامتر بی نیاز می نماید.

#### Algorithm 1. Social mimic algorithm

---

```

Initialize the Follower population  $Follower_i$  ( $i = 1, 2, \dots, pop\_size$ )
Initialize Social
Calculate the fitness of each Follower
Lider = the best fitness
While ( end condition not reached)
    For each Follower in Social
        Difference = (Lider - Fitness Of ( $Follower_i$ )) / Fitness Of ( $Follower_i$ )
        If ( Difference == 0)
            Difference = -Rand(1)
        End
        For  $J=1:N$ 
             $Follower_i(j) = Follower_i(j) + Difference \times Follower_i(j)$ 
        End
        Check if follower goes beyond the search space and amend it
        Update Social if new fitness is better
    End
    Calculate the fitness of each Follower
    Update Lider if there is a better solution
End
Return Lider

```

---

### ۳-۴ ویژگیهای SMO

همانطور که از شبه کد و مطالب گفته شده مشخص است SMO نیازمند هیچ پارامتر اولیه بجز تعداد جمعیت نیست. این ویژگی روش پیشنهادی را از تنظیم پارامترهای اولیه بی نیاز می نماید. با افزایش تعداد پارامترهای اولیه تنظیم مناسب آنها خود به یک مسئله بهینه سازی تبدیل خواهد شد. تابع انتخابی برای مراحل اکتشاف و بهرووری در SMO مطابق روابط ۳و۲ بسیار ساده بوده و کمترین پیچیدگی محاسباتی را دارند.

### ۴ نتایج

کارایی عددی الگوریتم SMO که در این مقاله ارائه شده است، بوسیله ۲۳ تابع بنچ مارک کلاسیک استفاده شده در ادبیات بهینه سازی [33-36] تحلیل شده است. جداول ۱ تا ۳ خلاصه اطلاعات هر تابع شامل تابع هزینه، تعداد متغیرهای تصمیم، دامنه تغییرات متغیرهای بهینه سازی و نقطه بهینه به صورت خلاصه آورده شده است. به طور کلی توابع آزمون در سه دسته سازماندهی شده اند. توابع بنچ مارک یونی مودال، مالتی مودال و مالتی مودال بعد- ثابت. توابع یونی مودال ( $f_1-f_7$ ) در جدول (۱) توصیف شده اند این توابع برای ارزیابی بهره وری الگوریتم مناسب هستند.

Table 1. Unimodal benchmark functions.

Function	Dim	Range	$f_{\min}$
$f_1(x) = \sum_{i=1}^n x_i^2$	30,300,3000	[-100,100]	0
$f_2(x) = \sum_{i=1}^n  x_i  + \prod_{i=1}^n  x_i $	30,300,3000	[-10,10]	0
$f_3(x) = \sum_{i=1}^n \left( \sum_{j=1}^i x_j \right)^2$	30,300,3000	[-100,100]	0
$f_4(x) = \max_i \{ x_i , 1 \leq i \leq n\}$	30	[-100,100]	0
$f_5(x) = \sum_{i=1}^{n-1} \left[ 100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right]$	30	[-30,30]	0
$f_6(x) = \sum_{i=1}^n ([x_i + 0.5])^2$	30	[-100,100]	0
$f_7(x) = \sum_{i=1}^n ix_i^4 + \text{random}[0,1)$	30	[-1.28,1.28]	0

در دسته دوم توابع مالتی مودال ( $f_8-f_{13}$ ) قرار دارند که هریک دارای تعداد بسیار زیادی بهینه محلی هستند. این توابع برای آزمایش توانایی اکتشاف و اجتناب از بهینگی محلی الگوریتم مفید هستند. جزئیات این توابع در جدول ۲ نمایش داده شده است. ویژگیهای مختلف دسته سوم، توابع مالتی مودال ابعاد ثابت شامل تابع هزینه، دامنه متغیرها و مقدار بهینه در جدول ۳ آورده شده است.

بخش بعدی به بررسی تعداد پارامتر الگوریتم SMO و تاثیر آن اختصاص یافته است. سپس نتایج مقایسه ای الگوریتم پیشنهادی با الگوریتم های شناخته شده Whale optimization algorithm (WOA), Grasshopper optimization algorithm (GOA) [26], Particle Swarm Optimization (PSO), Stochastic fractal search (SFS) [37], Grey Wolf Optimizer (GWO), Optics Inspired Optimization (OIO) [38], League Championship Algorithm (LCA) [39], Wind Driven Optimization (WDO) [40], Harmony search (HS) [41], Firefly Algorithm (FA) [42], Artificial Bee Colony (ABC), Biogeography Based Optimization (BBO) [43], Bat Algorithm (BA) [44], Teaching Learning Based Optimization (TLBO) [45] ارائه شده است.

Table 2. Multimodal benchmark functions.

Function	Dim	Range	$f_{\min}$
$f_8(x) = \sum_{i=1}^n -x_i \sin \sqrt{ x_i }$	30	[-100,100]	0
$f_9(x) = \sum_{i=1}^n [x_i^2 - 10 \cos(2\pi x_i) + 10]$	30,300,3000	[-10,10]	0

$f_{10}(x) = 20 \exp \left( -0.2 \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \right) - \exp \left( \frac{1}{n} \sum_{i=1}^n \cos(2\pi x_i) \right) + 20 + e$	30,300,3000	[-100,100]	0
$f_{11}(x) = \frac{1}{4000} \sum_{i=1}^n x_i^2 - \prod_{i=1}^n \cos \left( \frac{x_i}{\sqrt{i}} \right) + 1$	30	[-100,100]	0
$f_{12}(x) = \frac{\pi}{n} \left\{ \sin(\pi y_1) + \sum_{i=1}^{n-1} (y_i - 1)^2 [1 + \sin(\pi y_{i+1})] + (y_n - 1)^2 \right\} + \sum_{i=1}^n u(x_i, 10, 100, 4)$ $y_i = 1 + \frac{x_i + 1}{4}$ $u(x_i, a, k, m) = \begin{cases} k(x_i - a)^m & x_i > a \\ 0 & -a < x_i < a \\ k(-x_i - a)^m & x_i < -a \end{cases}$	30	[-30,30]	0
$f_{13}(x) = 0.1 \left\{ \sin^2(3\pi y_1) + \sum_{i=1}^n (x_i - 1)^2 [1 + \sin^2(3\pi y_i + 1)] + \sum_{i=1}^n u(x_i, 5, 100, 4) \right\} + \sum_{i=1}^n u(x_i, 5, 100, 4)$	30	[-100,100]	0

Table 3. Fixed-dimension benchmark functions.

Function	Dim	Range	$f_{\min}$
$f_{14}(x) = \left( \frac{1}{500} \sum_{j=1}^{25} \frac{1}{j + \sum_{i=1}^2 (x_i - a_{ij})^6} \right)^{-1}$	2	[-65,65]	1
$f_{15}(x) = \sum_{i=1}^{11} \left[ a_i - \frac{x_1(b_i^2 + b_i x_2)}{b_i^2 + b_i x_3 + x_4} \right]^2$	4	[-5,5]	0.00030
$f_{16}(x) = 4x_1^2 - 2.1x_1^4 + \frac{1}{3}x_1^6 + x_1x_2 - 4x_2^2 + 4x_2^4$	2	[-5,5]	-1.0316
$f_{17}(x) = \left( x_2 - \frac{5.1}{4\pi^2}x_1^2 + \frac{5}{\pi}x_1 - 6 \right)^2 + 10 \left( 1 - \frac{1}{8\pi} \right) (\cos(x_1)) + 10$	2	[-5,5]	0.398
$f_{18}(x) = \left[ 1 + (x_1 + x_2 + 1)^2 (19 - 14x_1 + 3x_1^2 - 14x_2 + 6x_1x_2 + 3x_2^2) \right] \cdot \left[ 30 + (2x_1 - 3x_2)^2 (18 - 32x_1 + 12x_1^2 + 48x_2 - 36x_1x_2 + 27x_2^2) \right]$	2	[-2,2]	3
$f_{19}(x) = -\sum_{i=1}^4 c_i \exp \left( -\sum_{j=1}^3 a_{ij} (x_j - p_{ij})^2 \right)$	3	[1,3]	-3.86
$f_{20}(x) = -\sum_{i=1}^4 c_i \exp \left( -\sum_{j=1}^6 a_{ij} (x_j - p_{ij})^2 \right)$	6	[0,10]	-3.32
$f_{21}(x) = -\sum_{i=1}^5 \left[ (x - a_i)(x - a_i)^T + c_i \right]^{-1}$	4	[0,10]	-10.1532
$f_{22}(x) = -\sum_{i=1}^7 \left[ (x - a_i)(x - a_i)^T + c_i \right]^{-1}$	4	[0,10]	-10.4028
$f_{23}(x) = -\sum_{i=1}^{10} c_i \exp \left( -\sum_{j=1}^6 a_{ij} (x_j - p_{ij})^2 \right)$	4	[0,10]	-10.5363



#### ۴-۱ تاثیر تعداد پارامتر بر الگوریتم بهینه سازی

با افزایش تعداد پارامترهای کنترلی در الگوریتم های بهینه سازی، تنظیم و یافتن مقادیر مناسب برای آنها خود یک مسله بهینه سازی است. الگوریتم smo فقط دارای پارامتر تعداد جمعیت است که در بین تمام روشهای بهینه سازی فرامکاشفه ای رایج است. استراتژی smo برای انجام مراحل اکتشاف و بهره وری آنرا از داشتن تعداد زیاد جمعیت بی نیاز نموده است. پارامترهای کنترلی الگوریتم های انتخاب شده برای مقایسه کارایی در حل مسائل بهینه سازی در جدول ۴ ارائه شده است.

Table 4. Controlling parameters of algorithms.

Algorithm	Parameter name
WOA	Shape of logarithmic spiral, and 3 random generated parameter
GOA	cmin, and cmax
PSO	Cognitive and social constant, Inertial weight
SFS	Gaussian walk, Maximum Diffusion Number
GWO	2 random generated parameter
OIO	Number of Light Points, random perturbation required
LCA	Lower and upper limit for retreat coefficient, Lower and limit for approach coefficient, Probability of success, alpha, and type of formation
WDO	RT coefficient, Gravitational constant, Constants in the update eq, Coriolis effect, and maximum allowed speed
HS	Harmony Memory Consideration Rate, Pitch Adjustment Rate, Fret Width (Bandwidth), Fret Width Damp Ratio
FA	Alpha, beta, and gamma
ABC	Number of food sources, value of limit, and the maximum cycle number (MCN).
BBO	Mutation probability, Number of the best solutions to keep from one generation to the next
BA	Loudness, pulse rate, frequency min and max
TLBO	Elitism in[46]
SMO	-

برای ارزیابی اثر تعداد جمعیت ( $N$ ) بر الگوریتم SMO توابع  $f_1, f_2, f_3, f_9, f_{10}$  انتخاب شده اند. برای حل توابع آزمون تعداد تکرار ۱۰۰ و تعداد جمعیت به ترتیب ۲ و ۳ و ۴ و ۵ و ۶ در نظر گرفته شده است. هریک از توابع آزمون به منظور تولید نتایج آماری ۵۰۰ بار حل شده اند. جداول ۵ نتایج بدست آمده برای توابع آزمون با تعداد متغیرتصمیم ۳۰۰ و ۳۰۰۰ را نشان می دهد.

Table 5. Result obtained from different number of follwer.

Follwer	Dim=300					Dim=3000				
	2	3	4	5	6	2	3	4	5	6
$f_1$	2.35E-111	5.07E-112	6.15E-108	7.56E-113	7.42E-112	2.02E-63	1.02E-53	2.02E-57	2.90E-59	4.85E-57
$f_2$	2.88E-56	2.65E-58	1.44E-57	8.67E-58	3.93E-52	1.98E-32	3.71E-31	1.38E-31	5.84E-32	2.26E-32
$f_3$	1.24E-110	1.67E-106	8.99E-121	7.31E-104	1.90E-104	6.87E-59	6.36E-58	3.22E-56	8.07E-57	5.75E-59
$f_9$	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00
$f_{10}$	8.88E-16	8.88E-16	8.88E-16	8.88E-16	8.88E-16	8.88E-16	8.88E-16	8.88E-16	8.88E-16	8.88E-16

به طور واضح مشخص است  $N = 2$  در اغلب مسائل نتیجه کار آمدتری تولید نموده است. مطابق جدول ۵،  $N = 3$  برای توابع با ابعاد متغیر تصمیم ۳۰۰ بهترین رنکینگ را داشته است. پس از آن  $N = 2$  در رتبه دوم قرار دارد. در حل مسائل، با ابعاد

متغیرتصمیم ۳۰۰۰ مطابق اطلاعات جدول ۵،  $N=2$  بهترین رتبه در توابع  $f_1, f_2, f_9, f_{10}$  داشته است. شکل ۱ رتبه بندی مقادیر متفاوت تعداد جمعیت را در ارزیابی توابع آزمون را تصویر نموده است.

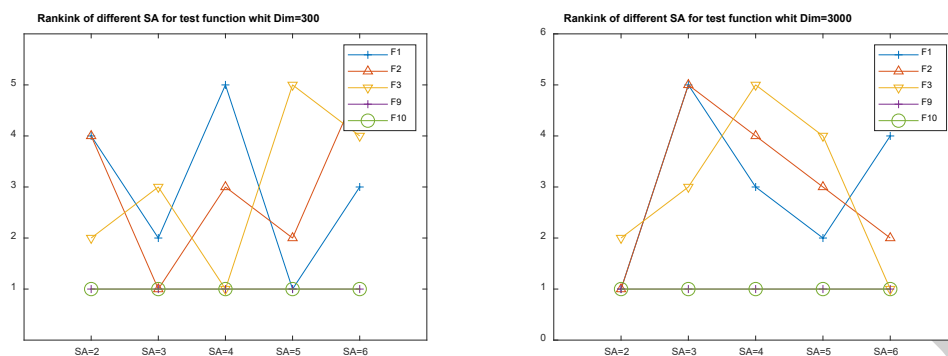


Fig 1. Ranking of  $N$  in different functions

بر اساس نتایج فوق می توان نتیجه گرفت الگوریتم پیشنهادی با استفاده از جمعیت ۲ یا ۳ توانایی حل مسائل بهینه سازی با ابعاد بسیار زیاد متغیر تصمیم را دارد. مطابق با منحنی همگرایی پاسخ رسم شده در شکل ۲ الگوریتم SMO توانسته است در تکرار کمتر از ۱۰ به سمت پاسخ مناسبی همگرا شود.

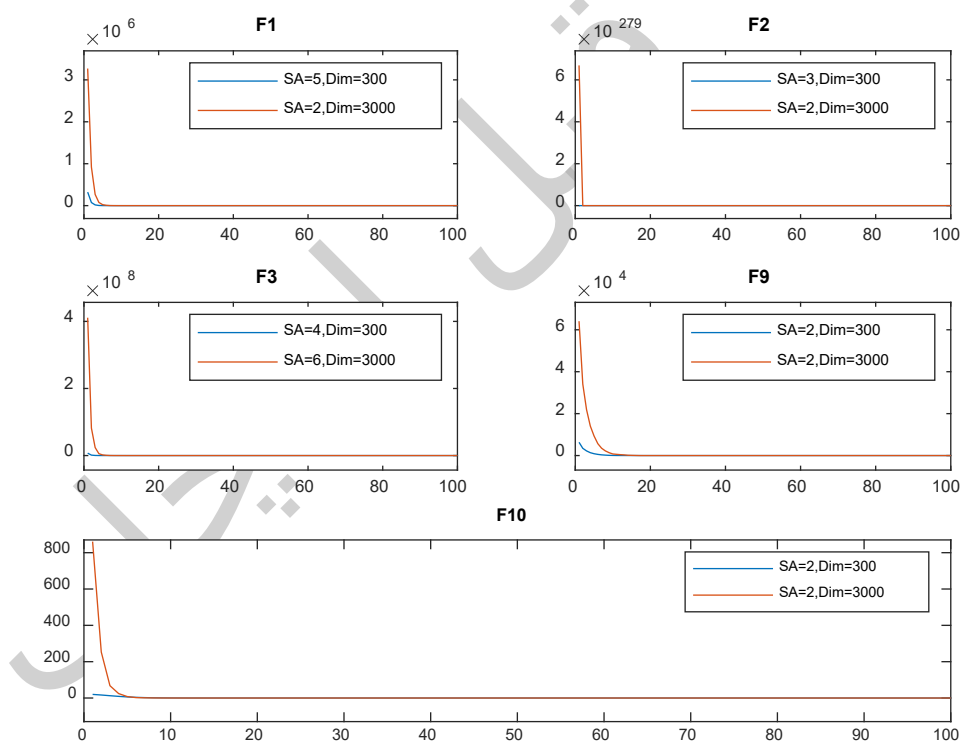


Fig 2. The convergence curve of SMO obtained in some of benchmark functions.

۴-۲ آزمایش مقایسه ای با سایر الگوریتم ها

همانطور که در بالا گفته شد سه مجموعه مسائل متفاوت برای نشان دادن کارایی الگوریتم پیشنهادی بکار گرفته شده است. برای ارزیابی نتایج ۱۴ الگوریتم اخیر و شناخته شده انتخاب شده اند. به منظور اطمینان از بهترین کارایی مقدار پارامترهای کنترل کننده سایر الگوریتم ها براساس مقدار آنها در آخرین نسخه (سورس کد) انتخاب شده است. در این آزمایش تعداد جمعیت و تعداد تکرار برای تمامی الگوریتم ها به ترتیب ۲ و ۱۰۰ در نظر گرفته شده است. هر تابع آزمون ۱۰۰ بار حل شده است. برای مقایسه بهتر کارایی الگوریتم ها علاوه بر بهترین پاسخ یافته شده توسط هر الگوریتم بدترین پاسخ و میانگین و انحراف معیار پاسخهای تولید شده در جدول ۶ تا ۸ ارائه شده اند. بر اساس نتایج، الگوریتم SMO در توابع  $f_1, f_2, f_3, f_4, f_9, f_{10}, f_{11}, f_{14}, f_{16}$  بهترین پاسخ را تولید نموده است. بدترین رتبه بدست آمده توسط SMO رتبه سیزده ام و در توابع  $f_{18}$  است.

Table 6. Result of unimodal functions

Function		SMO	WOA	GOA	PSO	SFS
F1	Best	7.02E-116	1.13E-06	3.25E+04	1.36E+04	2.46E-91
	Worst	1.31E-60	5.12E+03	9.46E+04	6.04E+04	3.50E-60
	Ave	1.56E-62	2.75E+02	6.03E+04	3.13E+04	3.58E-62
	Std	1.33E-61	6.99E+02	1.25E+04	8.70E+03	3.50E-61
F2	Best	1.02E-56	4.25E-07	6.18E+03	5.34E+01	5.15E-51
	Worst	9.30E-32	8.43E+00	5.87E+20	2.94E+09	1.04E-28
	Ave	9.97E-34	5.38E-01	6.66E+18	2.94E+07	1.08E-30
	Std	9.31E-33	1.17E+00	5.90E+19	2.94E+08	1.04E-29
F3	Best	2.49E-111	2.71E+04	2.96E+04	1.84E+04	6.33E-95
	Worst	1.92E-55	7.02E+05	2.54E+06	1.76E+05	1.26E-49
	Ave	1.92E-57	2.13E+05	3.52E+05	5.75E+04	1.26E-51
	Std	1.92E-56	1.39E+05	3.80E+05	2.70E+04	1.26E-50
F4	Best	1.04E-55	1.30E+00	6.14E+01	4.86E+01	8.03E-50
	Worst	1.16E-32	9.75E+01	9.72E+01	9.71E+01	6.77E-30
	Ave	1.17E-34	7.11E+01	8.41E+01	7.12E+01	1.64E-31
	Std	9.31E-33	2.65E+01	8.15E+00	9.64E+00	8.12E-31
F5	Best	2.90E+01	2.88E+01	8.98E+07	1.96E+07	2.87E+01
	Worst	2.90E+01	3.02E+07	4.14E+08	2.25E+08	2.90E+01
	Ave	2.90E+01	7.28E+05	2.29E+08	7.14E+07	2.90E+01
	Std	7.11E-03	3.14E+06	6.96E+07	3.78E+07	3.60E-02
F6	Best	6.08E+00	3.31E+00	2.88E+04	1.28E+04	4.83E+00
	Worst	7.50E+00	4.59E+03	8.64E+04	5.73E+04	7.39E+00
	Ave	7.40E+00	2.41E+02	5.89E+04	3.27E+04	6.84E+00
	Std	2.24E-01	7.08E+02	1.07E+04	9.14E+03	4.19E-01
F7	Best	1.93E-05	6.64E-03	3.84E+01	4.78E+00	9.57E-06
	Worst	4.44E-02	1.86E+01	2.85E+02	1.25E+02	1.73E-02
	Ave	1.10E-02	1.36E+00	1.70E+02	4.86E+01	4.10E-03
	Std	9.71E-03	3.28E+00	4.75E+01	2.52E+01	3.77E-03
Function		GWO	OIO	LCA	WDO	HS
F1	Best	1.02E-02	3.85E-08	1.46E+04	2.55E-02	6.45E+02
	Worst	4.91E+03	2.36E-03	5.78E+04	3.41E+02	2.90E+03
	Ave	3.83E+02	4.00E-05	3.75E+04	6.05E+01	1.64E+03
	Std	7.35E+02	2.36E-04	8.04E+03	8.38E+01	4.81E+02
F2	Best	2.56E-04	7.77E-04	6.14E+01	2.21E-02	7.75E+00
	Worst	2.03E+01	5.61E-02	5.17E+12	1.04E+01	1.89E+01
	Ave	4.16E+00	9.46E-03	5.20E+10	3.66E+00	1.32E+01
	Std	4.95E+00	8.63E-03	5.17E+11	2.26E+00	2.27E+00
F3	Best	4.55E+02	4.67E-01	4.45E+04	2.91E-01	1.13E+04
	Worst	3.08E+04	3.74E+04	2.47E+05	1.71E+03	3.83E+04
	Ave	9.45E+03	1.24E+03	9.22E+04	5.50E+02	2.46E+04
	Std	6.62E+03	3.98E+03	3.57E+04	3.87E+02	6.49E+03
F4	Best	3.65E+00	1.17E-04	6.79E+01	1.53E-01	2.87E+01
	Worst	6.13E+01	1.33E-02	9.69E+01	8.73E+00	4.52E+01
	Ave	2.81E+01	2.10E-03	8.57E+01	4.31E+00	3.80E+01

F5	Std	1.27E+01	1.87E-03	5.48E+00	2.19E+00	3.85E+00
	Best	4.02E+01	2.54E-04	1.87E+07	3.00E+01	9.99E+04
	Worst	7.29E+06	1.68E+01	2.67E+08	1.62E+04	1.15E+06
	Ave	1.76E+05	5.76E-01	1.09E+08	1.84E+03	3.38E+05
	Std	7.53E+05	2.41E+00	5.00E+07	3.07E+03	1.67E+05
F6	Best	4.60E+00	1.72E-05	1.84E+04	2.54E-01	8.37E+02
	Worst	4.76E+03	2.45E-02	6.74E+04	3.13E+02	2.99E+03
	Ave	3.30E+02	1.91E-03	3.86E+04	6.36E+01	1.68E+03
	Std	6.70E+02	3.44E-03	8.04E+03	8.13E+01	4.38E+02
F7	Best	5.82E-03	3.77E-04	1.65E+01	1.05E-02	3.00E-01
	Worst	1.90E+00	2.74E-02	1.23E+02	2.09E-01	1.82E+00
	Ave	2.72E-01	7.00E-03	5.97E+01	7.45E-02	8.62E-01
	Std	3.18E-01	5.24E-03	2.67E+01	4.01E-02	2.95E-01
Function		FA	ABC	BBO	BA	TLBO
F1	Best	2.46E+04	3.05E+04	5.94E+04	2.60E+04	1.44E-09
	Worst	8.51E+04	7.89E+04	1.14E+05	1.11E+05	7.46E-01
	Ave	5.48E+04	5.48E+04	8.99E+04	7.17E+04	3.85E-02
	Std	1.23E+04	1.19E+04	1.33E+04	1.79E+04	9.86E-02
F2	Best	7.79E+01	8.11E+01	1.09E+08	5.15E+02	1.18E-06
	Worst	7.83E+11	4.51E+11	1.70E+19	3.20E+16	1.46E-01
	Ave	1.11E+10	5.55E+09	5.00E+17	1.15E+15	2.23E-02
	Std	7.93E+10	4.51E+10	2.08E+18	4.70E+15	2.50E-02
F3	Best	3.26E+04	3.15E+04	8.26E+04	6.77E+04	6.15E-06
	Worst	1.67E+06	7.13E+05	4.06E+06	1.59E+06	5.91E+00
	Ave	2.09E+05	1.56E+05	7.04E+05	3.11E+05	5.61E-01
	Std	2.20E+05	1.07E+05	6.97E+05	2.50E+05	9.58E-01
F4	Best	6.55E+01	6.10E+01	7.58E+01	6.17E+01	5.85E-04
	Worst	9.44E+01	9.38E+01	9.98E+01	9.95E+01	6.90E-01
	Ave	8.20E+01	8.25E+01	9.53E+01	8.97E+01	1.37E-01
	Std	6.47E+00	7.51E+00	4.07E+00	6.91E+00	1.56E-01
F5	Best	5.43E+07	2.98E+07	1.58E+08	1.04E+08	2.87E+01
	Worst	3.49E+08	3.76E+08	6.61E+08	5.47E+08	3.40E+01
	Ave	1.81E+08	1.74E+08	4.15E+08	3.02E+08	2.92E+01
	Std	6.35E+07	6.65E+07	9.10E+07	1.07E+08	7.63E-01
F6	Best	2.87E+04	2.63E+04	5.53E+04	2.74E+04	3.70E+00
	Worst	8.14E+04	8.77E+04	1.22E+05	1.15E+05	6.43E+00
	Ave	5.33E+04	5.61E+04	8.87E+04	7.37E+04	5.09E+00
	Std	1.11E+04	1.16E+04	1.35E+04	1.90E+04	6.14E-01
F7	Best	1.51E+01	1.68E+01	6.84E+01	1.90E+01	4.16E-03
	Worst	1.74E+02	1.74E+02	3.63E+02	2.96E+02	1.20E-01
	Ave	6.78E+01	7.00E+01	2.15E+02	1.64E+02	4.02E-02
	Std	3.19E+01	2.99E+01	5.08E+01	6.38E+01	2.76E-02

Table 7. Result of multimodal functions

Function		SMO	WOA	GOA	PSO	SFS
F8	Best	-6.40E+02	-1.71E+03	-6.03E+02	-1.66E+01	-9.75E+02
	Worst	-1.73E+01	-4.10E+02	-2.86E+00	-3.00E+00	-3.39E+02
	Ave	-2.77E+02	-1.22E+03	-2.77E+02	-9.58E+00	-6.32E+02
	Std	1.29E+02	3.12E+02	1.26E+02	3.02E+00	1.30E+02
F9	Best	0.00E+00	1.71E-13	7.51E+02	8.66E+01	0.00E+00
	Worst	0.00E+00	3.86E+02	1.43E+03	2.43E+02	0.00E+00
	Ave	0.00E+00	7.06E+01	1.12E+03	1.55E+02	0.00E+00
	Std	0.00E+00	8.99E+01	1.34E+02	3.46E+01	0.00E+00
F10	Best	8.88E-16	5.04E-09	2.09E+01	4.26E+00	1.00E+00
	Worst	8.88E-16	2.11E+01	2.16E+01	1.52E+01	1.00E+00
	Ave	8.88E-16	8.62E+00	2.14E+01	9.16E+00	1.00E+00
	Std	9.91E-32	8.66E+00	1.18E-01	2.56E+00	0.00E+00
F11	Best	0.00E+00	8.22E-10	1.02E+01	3.09E+00	0.00E+00
	Worst	0.00E+00	3.09E+00	2.69E+01	1.45E+01	0.00E+00
	Ave	0.00E+00	7.70E-01	1.64E+01	8.78E+00	0.00E+00

F12	Std	0.00E+00	5.73E-01	2.80E+00	2.52E+00	0.00E+00
	Best	5.77E-01	3.47E-01	2.17E+06	5.40E+01	6.69E-01
	Worst	1.67E+00	2.76E+06	6.52E+07	1.78E+07	1.61E+00
	Ave	1.55E+00	1.32E+05	2.25E+07	4.23E+06	1.26E+00
	Std	2.20E-01	4.02E+05	1.31E+07	4.08E+06	2.26E-01
F13	Best	2.99E+00	1.60E+00	6.06E+09	7.38E+08	2.61E+00
	Worst	3.00E+00	2.41E+09	4.51E+10	2.88E+10	3.00E+00
	Ave	3.00E+00	2.13E+08	2.07E+10	7.58E+09	2.98E+00
	Std	9.82E-04	5.12E+08	7.51E+09	5.05E+09	6.26E-02
Function		GWO	OIO	LCA	WDO	HS
F8	Best	-1.00E+03	-1.91E+03	-1.16E+03	-1.88E+03	-1.88E+03
	Worst	-2.67E+02	-1.64E+03	-5.00E+02	-2.21E+02	-1.69E+03
	Ave	-6.42E+02	-1.89E+03	-8.05E+02	-8.67E+02	-1.79E+03
	Std	1.48E+02	4.11E+01	1.33E+02	5.49E+02	3.49E+01
F9	Best	1.54E-02	3.54E-07	3.14E+02	4.94E-01	9.28E+01
	Worst	2.56E+02	3.25E+01	8.31E+02	2.75E+02	2.04E+02
	Ave	8.66E+01	1.43E+00	5.87E+02	2.00E+02	1.51E+02
	Std	5.86E+01	5.73E+00	1.01E+02	7.95E+01	2.20E+01
F10	Best	1.00E+00	1.00E+00	3.87E+00	1.00E+00	1.12E+00
	Worst	2.14E+00	1.00E+00	1.71E+01	1.10E+00	1.79E+00
	Ave	1.12E+00	1.00E+00	1.01E+01	1.02E+00	1.41E+00
	Std	2.00E-01	2.22E-06	2.31E+00	2.30E-02	1.34E-01
F11	Best	3.62E-02	1.41E-06	7.12E+00	5.70E-03	1.17E+00
	Worst	1.48E+00	2.04E-03	1.56E+01	1.11E+00	1.97E+00
	Ave	8.40E-01	2.07E-04	1.06E+01	7.58E-01	1.41E+00
	Std	3.55E-01	3.69E-04	1.99E+00	3.54E-01	1.32E-01
F12	Best	6.18E-01	2.30E-06	9.16E+05	7.77E-03	3.23E+00
	Worst	1.29E+02	1.00E-03	2.49E+07	4.54E+00	2.21E+01
	Ave	8.83E+00	1.75E-04	9.32E+06	1.11E+00	8.46E+00
	Std	1.53E+01	1.93E-04	6.09E+06	9.66E-01	2.95E+00
F13	Best	3.12E+00	2.13E-05	1.86E+09	3.24E-01	1.30E+06
	Worst	5.41E+08	6.44E-03	2.35E+10	9.00E+04	3.97E+07
	Ave	1.45E+07	8.79E-04	1.03E+10	1.95E+03	1.29E+07
	Std	6.32E+07	9.96E-04	4.30E+09	1.12E+04	8.77E+06
Function		FA	ABC	BBO	BA	TLBO
F8	Best	-6.84E+02	-7.24E+02	-5.68E+02	-7.39E+02	-1.36E+03
	Worst	-4.31E+01	-1.03E+02	1.72E+02	8.96E+01	-2.76E+02
	Ave	-3.61E+02	-3.91E+02	-1.34E+02	-3.04E+02	-7.28E+02
	Std	1.37E+02	1.16E+02	1.66E+02	1.67E+02	2.39E+02
F9	Best	5.17E+02	5.44E+02	8.73E+02	5.39E+02	3.31E-06
	Worst	1.13E+03	1.03E+03	1.52E+03	1.51E+03	2.05E+01
	Ave	7.83E+02	7.64E+02	1.20E+03	1.08E+03	1.99E+00
	Std	1.27E+02	1.11E+02	1.32E+02	2.15E+02	3.54E+00
F10	Best	8.32E+00	8.43E+00	1.54E+01	9.12E+00	1.00E+00
	Worst	2.09E+01	2.21E+01	3.34E+01	2.82E+01	1.00E+00
	Ave	1.46E+01	1.45E+01	2.41E+01	1.85E+01	1.00E+00
	Std	3.00E+00	2.93E+00	3.47E+00	4.26E+00	4.18E-05
F11	Best	8.33E+00	9.73E+00	1.52E+01	7.64E+00	3.64E-08
	Worst	2.53E+01	2.38E+01	3.16E+01	2.81E+01	3.41E-01
	Ave	1.47E+01	1.54E+01	2.43E+01	1.95E+01	3.23E-02
	Std	3.13E+00	2.82E+00	3.38E+00	4.22E+00	6.93E-02
F12	Best	2.38E+06	6.32E+05	1.44E+07	1.55E+06	2.12E-01
	Worst	4.91E+07	4.09E+07	1.07E+08	8.16E+07	1.26E+00
	Ave	1.49E+07	1.59E+07	5.29E+07	3.19E+07	7.12E-01
	Std	9.05E+06	7.54E+06	1.67E+07	1.91E+07	2.57E-01
F13	Best	4.72E+09	5.11E+09	1.66E+10	5.56E+09	2.16E+00
	Worst	3.13E+10	3.08E+10	6.42E+10	5.37E+10	3.12E+00
	Ave	1.64E+10	1.69E+10	4.01E+10	2.87E+10	2.69E+00
	Std	6.21E+09	5.35E+09	1.00E+10	1.12E+10	1.76E-01

Table 8. Result of fixed-multimodal functions

Function		SMO	WOA	GOA	PSO	SFS
F14	Best	9.99E-01	1.05E+00	2.08E+00	9.98E-01	9.98E-01
	Worst	1.27E+01	2.72E+02	5.00E+02	4.92E+02	1.27E+01
	Ave	1.18E+01	1.64E+01	2.93E+02	2.18E+01	1.05E+01
	Std	2.54E+00	2.81E+01	2.04E+02	6.32E+01	3.87E+00
F15	Best	8.51E-04	7.54E-04	1.68E-02	8.15E-04	4.54E-04
	Worst	1.48E-01	1.24E-01	3.61E+03	2.22E+01	1.09E-01
	Ave	8.93E-02	2.15E-02	7.90E+01	4.58E-01	2.55E-02
	Std	5.41E-02	2.53E-02	3.85E+02	2.42E+00	2.90E-02
F16	Best	-1.03E+00	-1.03E+00	-1.03E+00	-1.03E+00	-1.03E+00
	Worst	-1.23E-01	1.76E+00	1.90E+03	1.42E-01	-2.10E-01
	Ave	-6.42E-01	-7.25E-01	3.36E+02	-6.73E-01	-9.37E-01
	Std	2.74E-01	4.95E-01	4.60E+02	4.14E-01	1.55E-01
F17	Best	3.99E-01	3.98E-01	6.52E-01	3.98E-01	3.98E-01
	Worst	5.56E+01	1.96E+01	1.54E+02	1.02E+02	9.21E+00
	Ave	1.99E+01	3.60E+00	2.58E+01	4.96E+00	6.51E-01
	Std	1.88E+01	4.77E+00	3.04E+01	1.47E+01	9.97E-01
F18	Best	3.02E+00	3.00E+00	4.01E+00	3.00E+00	3.00E+00
	Worst	6.00E+02	7.01E+03	8.54E+04	9.41E+02	9.27E+01
	Ave	2.10E+02	1.46E+02	5.26E+03	1.23E+02	2.11E+01
	Std	2.20E+02	7.29E+02	1.23E+04	2.62E+02	1.97E+01
F19	Best	-2.90E-01	-3.86E+00	-1.45E-01	-3.00E-01	-2.52E-01
	Worst	-9.74E-03	-6.22E-01	-6.79E-56	-1.47E-22	-1.01E-02
	Ave	-1.24E-01	-2.97E+00	-1.50E-03	-1.36E-01	-1.40E-01
	Std	6.72E-02	9.12E-01	1.45E-02	1.09E-01	5.30E-02
F20	Best	-2.75E+00	-2.39E+00	-2.18E-24	-1.53E+00	-2.84E+00
	Worst	0.00E+00	-5.11E-03	0.00E+00	0.00E+00	-3.14E-02
	Ave	-2.31E-01	-3.15E-01	-2.45E-26	-5.12E-02	-8.98E-01
	Std	4.06E-01	5.74E-01	2.18E-25	1.87E-01	6.58E-01
F21	Best	-8.88E+00	-9.45E+00	-1.18E+00	-1.02E+01	-8.00E+00
	Worst	-3.33E-01	-2.73E-01	-6.63E-02	-1.65E-01	-5.62E-01
	Ave	-1.67E+00	-1.58E+00	-2.16E-01	-3.11E+00	-3.15E+00
	Std	1.27E+00	1.56E+00	1.46E-01	2.90E+00	1.49E+00
F22	Best	-6.46E+00	-9.92E+00	-9.59E-01	-1.04E+01	-7.87E+00
	Worst	-6.07E-01	-2.94E-01	-1.14E-01	-2.76E-01	-7.53E-01
	Ave	-2.11E+00	-1.76E+00	-2.94E-01	-3.77E+00	-3.19E+00
	Std	1.27E+00	1.68E+00	1.26E-01	2.88E+00	1.52E+00
F23	Best	-7.57E+00	-7.51E+00	-1.06E+00	-1.05E+01	-1.04E+01
	Worst	-4.37E-01	-3.22E-01	-1.97E-01	-3.34E-01	-1.00E+00
	Ave	-2.17E+00	-1.76E+00	-4.13E-01	-3.13E+00	-3.54E+00
	Std	1.16E+00	1.43E+00	1.98E-01	2.55E+00	1.67E+00
Function		GWO	OIO	LCA	WDO	HS
F14	Best	1.59E+00	9.98E-01	9.98E-01	9.98E-01	9.98E-01
	Worst	5.77E+01	1.99E+00	5.00E+02	2.28E+01	5.93E+00
	Ave	1.23E+01	1.02E+00	1.04E+02	5.62E+00	1.19E+00
	Std	6.48E+00	1.40E-01	1.75E+02	6.24E+00	7.38E-01
F15	Best	3.34E-04	3.47E-04	9.85E-04	3.53E-04	4.12E-04
	Worst	1.49E-01	3.48E-03	8.67E+01	4.27E-02	6.33E-02
	Ave	2.49E-02	1.65E-03	1.03E+00	4.49E-03	1.03E-02
	Std	3.84E-02	7.13E-04	8.66E+00	6.37E-03	1.04E-02
F16	Best	-1.03E+00	-1.03E+00	-1.03E+00	-1.03E+00	-1.03E+00
	Worst	-2.12E-01	-1.03E+00	1.80E+03	-7.54E-01	-1.03E+00
	Ave	-1.01E+00	-1.03E+00	5.02E+01	-1.02E+00	-1.03E+00
	Std	8.29E-02	3.33E-12	2.43E+02	3.43E-02	8.53E-05
F17	Best	3.98E-01	3.98E-01	3.98E-01	3.98E-01	3.98E-01
	Worst	2.07E+01	3.98E-01	1.17E+02	4.70E+00	3.98E-01
	Ave	3.72E+00	3.98E-01	8.38E+00	5.85E-01	3.98E-01
	Std	6.31E+00	8.93E-16	1.66E+01	5.59E-01	3.24E-05
F18	Best	3.00E+00	3.00E+00	3.00E+00	3.01E+00	3.00E+00
	Worst	6.11E+02	3.00E+00	5.04E+03	8.40E+02	9.71E+01
	Ave	5.08E+01	3.00E+00	3.34E+02	1.89E+01	1.89E+01
	Std	1.15E+02	7.38E-15	8.06E+02	8.38E+01	2.52E+01
F19	Best	-3.00E-01	-3.00E-01	-3.00E-01	-3.00E-01	-3.00E-01
	Worst	-3.00E-01	-3.00E-01	-1.42E-64	-1.02E-09	-3.00E-01

F20	Ave	-3.00E-01	-3.00E-01	-8.84E-02	-1.67E-01	-3.00E-01
	Std	5.02E-16	4.96E-05	1.17E-01	1.29E-01	5.02E-16
	Best	-3.31E+00	NA	-2.50E+00	-3.03E+00	-3.32E+00
	Worst	-4.38E-04	NA	0.00E+00	-8.81E-137	-3.20E+00
	Ave	-1.69E+00	NA	-2.15E-01	-3.81E-01	-3.27E+00
F21	Std	1.15E+00	NA	4.63E-01	6.88E-01	5.85E-02
	Best	-1.00E+01	-1.02E+01	-1.00E+01	-1.01E+01	-1.02E+01
	Worst	-3.55E-01	-5.56E+00	-2.10E-01	-1.11E+00	-2.63E+00
	Ave	-4.35E+00	-1.01E+01	-2.45E+00	-6.34E+00	-5.77E+00
	Std	3.25E+00	5.49E-01	2.61E+00	3.05E+00	3.24E+00
F22	Best	-1.03E+01	-1.04E+01	-1.04E+01	-1.04E+01	-1.04E+01
	Worst	-3.54E-01	-3.72E+00	-1.69E-01	-1.42E+00	-1.84E+00
	Ave	-3.99E+00	-1.03E+01	-2.88E+00	-6.61E+00	-5.04E+00
	Std	3.14E+00	6.68E-01	2.54E+00	3.08E+00	3.15E+00
F23	Best	-1.03E+01	-1.05E+01	-1.04E+01	-1.05E+01	-1.05E+01
	Worst	-5.57E-01	-1.05E+01	-3.39E-01	-1.41E+00	-1.68E+00
	Ave	-4.15E+00	-1.05E+01	-2.59E+00	-6.69E+00	-4.42E+00
	Std	3.07E+00	7.07E-03	2.02E+00	3.37E+00	3.08E+00
Function		FA	ABC	BBO	BA	TLBO
F14	Best	9.98E-01	9.98E-01	3.43E+00	1.62E+00	9.98E-01
	Worst	5.00E+02	5.00E+02	5.00E+02	5.00E+02	1.83E+01
	Ave	3.58E+01	2.13E+01	4.65E+02	2.91E+02	9.47E+00
	Std	9.61E+01	5.51E+01	9.60E+01	2.12E+02	3.62E+00
F15	Best	8.82E-04	1.54E-03	3.07E-02	1.23E-03	4.49E-04
	Worst	9.22E+01	4.16E+01	1.33E+03	4.52E+03	1.40E-01
	Ave	1.84E+00	1.08E+00	5.13E+01	5.25E+01	3.26E-02
	Std	9.94E+00	4.58E+00	1.59E+02	4.53E+02	3.78E-02
F16	Best	-1.03E+00	-1.03E+00	-8.46E-01	-1.03E+00	-1.03E+00
	Worst	3.98E+01	1.34E+02	3.18E+03	1.13E+03	-4.57E-09
	Ave	4.48E-01	1.88E+00	4.44E+02	4.62E+01	-7.58E-01
	Std	5.60E+00	1.47E+01	6.69E+02	1.52E+02	3.67E-01
F17	Best	3.98E-01	3.98E-01	7.40E-01	4.16E-01	3.98E-01
	Worst	1.80E+02	7.92E+01	2.19E+02	1.31E+02	1.78E+01
	Ave	1.08E+01	6.85E+00	4.55E+01	1.58E+01	1.76E+00
	Std	2.14E+01	1.37E+01	4.96E+01	2.32E+01	2.35E+00
F18	Best	3.00E+00	3.00E+00	5.00E+00	3.00E+00	3.00E+00
	Worst	2.02E+03	2.77E+03	1.43E+05	1.20E+04	2.35E+02
	Ave	1.22E+02	1.21E+02	1.12E+04	7.08E+02	3.97E+01
	Std	3.18E+02	3.60E+02	2.35E+04	1.84E+03	3.64E+01
F19	Best	-3.00E-01	-2.95E-01	-5.22E-02	-3.00E-01	-3.00E-01
	Worst	-1.14E-27	-9.80E-30	-4.96E-78	-2.25E-29	-3.00E-01
	Ave	-7.87E-02	-7.81E-02	-6.97E-04	-1.70E-01	-3.00E-01
	Std	1.09E-01	1.03E-01	5.40E-03	1.24E-01	5.02E-16
F20	Best	-7.14E-14	-2.62E-07	-2.92E-20	-2.00E-01	-3.29E+00
	Worst	0.00E+00	0.00E+00	0.00E+00	0.00E+00	-5.16E-02
	Ave	-7.14E-16	-2.62E-09	-3.15E-22	-2.83E-03	-1.66E+00
	Std	7.14E-15	2.62E-08	2.92E-21	2.03E-02	1.13E+00
F21	Best	-1.02E+01	-1.02E+01	-8.85E-01	-2.49E+00	-9.98E+00
	Worst	-1.59E-01	-1.26E-01	-8.14E-02	-9.47E-02	-4.93E-01
	Ave	-1.21E+00	-1.58E+00	-2.14E-01	-4.30E-01	-2.94E+00
	Std	1.71E+00	2.25E+00	1.29E-01	3.88E-01	2.02E+00
F22	Best	-1.04E+01	-1.04E+01	-6.92E-01	-2.32E+00	-5.73E+00
	Worst	-2.14E-01	-1.71E-01	-1.02E-01	-1.40E-01	-6.00E-01
	Ave	-2.09E+00	-1.67E+00	-2.68E-01	-4.74E-01	-2.64E+00
	Std	2.43E+00	1.82E+00	1.27E-01	3.43E-01	1.43E+00
F23	Best	-1.05E+01	-1.05E+01	-1.46E+00	-5.47E+00	-8.62E+00
	Worst	-2.79E-01	-3.24E-01	-1.83E-01	-2.19E-01	-5.22E-01
	Ave	-2.36E+00	-2.31E+00	-4.11E-01	-7.03E-01	-2.90E+00
	Std	2.41E+00	2.12E+00	2.20E-01	6.47E-01	1.67E+00

اطلاعات جدولهای ۶ تا ۸ در جدول ۹ خلاصه شده است. عدد اول هر ستون تعداد مسائلی است که الگوریتم SMO توانسته پاسخی با دقت بالاتر نسبت به الگوریتم دیگر بیابد. مطابق اطلاعات نمایش داده شده الگوریتم SMO نتایج رقابتی در مقایسه با سایر روشها بدست آورده است. فقط الگوریتم SFS در دو مسئله پاسخی مشابه SMO تولید نموده است. در نهایت می توان گفت در حل ۲۳ مسئله بهینه سازی معرفی شده روش پیشنهادی نسبت به سایر روشها توانسته است پاسخ دقیقتر بیش از نیمی از مسائل را با هزینه ارزیابی کمتر بیابد.

Table 9. Result summation of table 6-8.

SMO vs#	WOA	GOA	PSO	SFS	GWO	OIO	LCA	WDO	HS	FA	ABC	BBO	BA	TLBO
Better	13	22	15	11	14	12	17	12	15	17	17	22	21	12
As good as	0	0	0	2	0	0	0	0	0	0	0	0	0	0
Worst	10	1	8	10	9	11	6	11	8	6	6	1	2	11

### ۳-۴ حل مسائل کلاسیک مهندسی

حل مسائل طراحی ساختاری با استفاده از تکنیکهای بهینه سازی تصادفی یکی از جهت های تحقیقاتی عامه پسند (محبوب) است. در این بخش **دو** مسئله طراحی مهندسی با استفاده از SMO حل و نتایج بدست آمده با نتایج منتشر شده در مقالات مقایسه شده است.

#### Cantilever beam design problem ۱-۳-۴

مطابق شکل ۳ cantilever beam از پنج بخش مربعی پوک ساخته شده است. طول این پنج بخش پارامترهای مسئله هستند. همچنین مسئله دارای یک محدودیت (قید) است که نباید توسط طراحی بهینه نهایی نقض شود.




Fig 3. Cantilever beam design problem.

این مسئله طراحی به صورت زیر فرموله شده است.

$$\begin{aligned}
 \text{Consider} \quad & \bar{X} = [x_1 \ x_2 \ x_3 \ x_4 \ x_5] \\
 \text{Minimize} \quad & f(\bar{X}) = 0.6224(x_1, x_2, x_3, x_4, x_5) \\
 \text{Subject to} \quad & g_1(\bar{X}) = \frac{61}{x_1^3} + \frac{27}{x_2^3} + \frac{19}{x_3^3} + \frac{7}{x_4^3} + \frac{1}{x_5^3} - 1 \leq 0 \\
 \text{Variable range} \quad & 0.01 \leq x_1, x_2, x_3, x_4, x_5 \leq 100
 \end{aligned}$$

برای حل این مسئله الگوریتم SMO با ۲ عامل و حداکثر ۳۰۰ تکرار برای تعیین مقادیر بهینه بکارگرفته شده است. نتایج مقایسه ای الگوریتم های



ALO, SSA, GOA, SOS, cuckoo search algorithm (CS) [47], Generalized Convex Approximation (GCA) [48], Method of Moving Asymptotes (MMA) [48]

برای واریسی در جدول 10 ارایه شده اند.

Table 10. Comparison result for cantilever design problem.

Algorithm	Optimal values					Optimal cost
	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	
SMO	5.78691656	5.051692965	4.227690161	3.73905533	2.257392706	1.31095
ALO	6.01812	5.31142	4.48836	3.49751	2.158329	1.33995
SSA	6.015135	5.309305	4.495007	3.501426	2.152788	1.33996
GOA	6.011674	5.31297	4.48307	3.50279	2.16333	1.33996
SOS	6.01878	5.30344	4.49587	3.49896	2.15564	1.33996
CS	6.0089	5.3049	4.5023	3.5077	2.1504	1.33999
MMA	6.0100	5.3000	4.4900	3.4900	2.1500	1.3400
GCA_I	6.0100	5.3000	4.4900	3.4900	2.1500	1.3400
GCA_II	6.0100	5.3000	4.4900	3.4900	2.1500	1.3400




Fig 4. Pressure vessel design problem.

#### Pressure vessel design problem ۲-۳-۴

این مسئله در خصوص طراحی مخزن استوانه ای خاص است که دو انتهای آن بوسیله نیم کره هایی مسدود شده اند. همانند تمامی مسائل بهینه سازی هدف این مسئله کاهش هزینه ساخت، مواد، شکل دهی و جوشکاری است. شمای مسئله برای درک بهتر در شکل ۴ نمایش داده شده است. این مسئله دارای ۴ پارامتر و ۴ قید است. که بصورت زیر می تواند نوشته شود.

$$\begin{aligned}
 &\text{Consider } \vec{X} = [x_1 \ x_2 \ x_3 \ x_4] \\
 &\text{Minimize } f(\vec{X}) = 0.62224x_1x_3x_4 + 1.7781x_2x_3^2 + 3.1661x_4x_1^2 + 19.84x_3x_1^2 \\
 &\text{Subject to } g_1(\vec{X}) = -x_1 + 0.0193x_3 \leq 0 \\
 &\quad g_2(\vec{X}) = -x_3 + 0.00954x_3 \leq 0 \\
 &\quad g_3(\vec{X}) = -\pi x_3^2x_4 - \frac{4}{3}\pi x_3^3 + 1296000 \leq 0 \\
 &\quad g_4(\vec{X}) = x_4 - 240 \leq 0 \\
 &\text{Variable range } 0 \leq x_1, x_2 \leq 99 \\
 &\quad 10 \leq x_3, x_4 \leq 200
 \end{aligned}$$

در تحقیقات، روشهای گوناگونی برای حل این مسئله بکار گرفته شده است. برخی از این روشها الگوریتمهای

VPL, charged system search (CSS) [49], Hybridizing particle swarm optimization with differential evolution (PSO-DE) [50], galaxy-based search algorithm (GSA) [51], improved ACO [52], co-evolutionary differential

evolution (CDE) [53], WOA, Evolution strategies (ES) [54], different genetic algorithms (GA) [55-57], co-evolutionary particle swarm optimization approach (CPSO) [58], improved HS [59], augmented Lagrangian multiplier approach [60], branch and bound method [61]

هستند. بهترین نتیجه پیدا شده توسط هر روش در جدول ۱۱ ارائه شده است. نتایج قانع کننده جدول ۱۱ توانایی الگوریتم SMO در حل موثر این مسئله را نشان می دهد.

Table 11. Comparison result for pressure vessel design problem.

Algorithm	Optimal values				Optimal cost
	$T_s$	$T_h$	$R$	$L$	
SMO	0.824248041	0.407150024	42.36584829	173.7973031	6021.6291
VPL	0.815200	0.426500	42.0912541	176.742314	6044.9565
CSS	0.812500	0.437500	42.103624	176.572656	6059.0888
PSO-DE	0.8125	0.4375	42.098445596	176.636596	6059.7143
ACO	0.812500	0.437500	42.098353	176.637751	6059.7258
CDE	0.812500	0.437500	42.098411	176.637690	6059.7340
WOA	0.812500	0.437500	42.0982699	176.638998	6059.7410
ES	0.812500	0.437500	42.098087	176.640518	6059.7456
GA (Coello & Montes)	0.937500	0.437500	42.097398	176.654050	6059.9463
CPSO	0.812500	0.437500	42.091266	176.746500	6061.0777
GA (Coello)	0.812500	0.437500	40.323900	200.000000	6288.7445
GA (Deb & Gene)	0.812500	0.437500	48.329000	112.679000	6410.3811
GSA	0.937500	0.50000	48.329	112.679	6410.3811
Improved HS	1.125000	0.625000	58.29015	43.69268	7197.730
ALM	1.125000	0.625000	58.2910	43.69	7198.0428
Branch and Bound	1.125000	0.625000	47.7000	117.7010	8129.1036

## ۵- استنتاج

در این مقاله الگوریتم جدید بهینه سازی مبتنی بر ازدحام با الهام از رفتار تقلید گرایانه افراد ارائه شد. روش پیشنهادی ( که SMO نامیده شده است) شامل یک عملگر تقلید برای شبیه سازی جستجو در فضای پاسخ مسئله بهینه سازی است. عدم نیاز SMO به عملگر کنترلی پیاده سازی آنرا بسیار ساده نموده است. از طرفی ایده مطرح شده در انجام مراحل اکتشاف و بهره وری توانایی غلبه بر ضعف عمومی روشهای مبتنی بر جمعیت یعنی نیاز به تعداد نسبتاً زیاد جمعیت اولیه را برای SMO فراهم نموده است.

برای ارزیابی کارایی SMO مجموعه ای شامل ۲۳ تابع بنچ مارک برای تحلیل اکتشاف، بهره وری، اجتناب از بهینه محلی، رفتار همگرایی و توانایی حل مسئله با ابعاد زیاد متغیر تصمیم انتخاب شده اند. در ادامه SMO با ۱۴ الگوریتم بهینه سازی شناخته شده و State-of-the-art مقایسه شده است. نتایج، کارایی بالاتر SMO را نسبت به الگوریتمهای مطرح شده نشان داده است.

مطالعات آتی الگوریتم SMO به دو دسته توسعه الگوریتم و کاربردهای دنیای واقعی تقسیم می شوند. توسعه نسخه باینری و چندهدفه الگوریتم برای حل مسائل گسسته و چند هدفه ممکن است. حل مسائل بهینه سازی در حوزه های مختلف می تواند توسعه ای با ارزش از الگوریتم پیشنهادی باشد.

- [١] S. Mirjalili, S. M. Mirjalili, and A. Lewis, "Grey Wolf Optimizer," *Advances in Engineering Software*, vol. 69, pp. 46-61, 2014.
- [٢] S. Mirjalili and A. Lewis, "S-shaped versus V-shaped transfer functions for binary Particle Swarm Optimization," *Swarm and Evolutionary Computation*, vol. 9, pp. 1-14, 2013.
- [٣] L. Davis, "Bit-Climbing, Representational Bias, and Test Suite Design," in *ICGA*, 1991.
- [٤] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, "Optimization by Simulated Annealing," *Science*, vol. 220, pp. 671-680, 1983.
- [٥] F. Marini and B. Walczak, "Particle swarm optimization (PSO). A tutorial," *Chemometrics and Intelligent Laboratory Systems*, vol. 149, pp. 153-165, 2015.
- [٦] M. Dorigo, "Optimization, learning and natural algorithms," *PhD Thesis, Politecnico di Milano*, 1992.
- [٧] R. S. Parpinelli and H. S. Lopes, "New inspirations in swarm intelligence: a survey," *International Journal of Bio-Inspired Computation*, vol. 3, no. 1, pp. 1-16, 2011.
- [٨] H. A. Abbass, "MBO: marriage in honey bees optimization-a Haplometrosis polygynous swarming approach," in *Proceedings of the 2001 Congress on Evolutionary Computation (IEEE Cat. No.01TH8546)*, 2001, vol. 1, pp. 207-214.
- [٩] D. Karaboga and B. Basturk, "A powerful and efficient algorithm for numerical function optimization: artificial bee colony (ABC) algorithm," *Journal of Global Optimization*, journal article vol. 39, no. 3, pp. 459-471, 2007.
- [١٠] P. Bhambu, S. Sharma, and S. Kumar, "Modified Gbest Artificial Bee Colony Algorithm," Singapore, 2018, pp. 665 :٦٧٧-Springer Singapore.
- [١١] K. N. Krishnanand and D. Ghose, "Detection of multiple source locations using a glowworm metaphor with applications to collective robotics," in *Proceedings 2005 IEEE Swarm Intelligence Symposium, 2005. SIS 2005.*, 2005, pp. 84.٩١-
- [١٢] X.-S. Yang, *Nature-Inspired Metaheuristic Algorithms*. Luniver Press, 2010.
- [١٣] S. L. Tilahun and H. C. Ong, "Modified Firefly Algorithm," *Journal of Applied Mathematics*, vol. 2012, p. 12, 2012, Art. no. 467631.
- [١٤] J. J. Q. Yu and V. O. K. Li, "A social spider algorithm for global optimization," *Applied Soft Computing*, vol. 30, pp. 614-627, 2015.
- [١٥] E. Cuevas, M. Cienfuegos, D. Zaldívar, and M. Pérez-Cisneros, "A swarm optimization algorithm inspired in the behavior of the social-spider," *Expert Systems with Applications*, vol. 40, no. 16, pp. 6374-6384, 2013.
- [١٦] R. Moghdani and K. Salimifard, "Volleyball Premier League Algorithm," *Applied Soft Computing*, vol. 64, pp. 161-185, 2018.
- [١٧] E. Fadakar and M. Ebrahimi, "A new metaheuristic football game inspired algorithm," in *2016 1st Conference on Swarm Intelligence and Evolutionary Computation (CSIEC)*, 2016, pp. 6-11.
- [١٨] C. Gong, "Opposition-Based Adaptive Fireworks Algorithm," *Algorithms*, vol. 9, no. 3, pp. 1-13, 2016.
- [١٩] G.-G. Wang, S. Deb, and Z. Cui, "Monarch butterfly optimization," *Neural Computing and Applications*, journal article pp. 1-20, 2015.
- [٢٠] S. Mirjalili, "SCA: A Sine Cosine Algorithm for solving optimization problems," *Knowledge-Based Systems*, vol. 96, pp. 120-133, 2016.
- [٢١] M.-Y. Cheng and D. Prayogo, "Symbiotic Organisms Search: A new metaheuristic optimization algorithm," *Computers & Structures*, vol. 139, pp. 98-112, 2014.
- [٢٢] S. Mirjalili and A. Lewis, "The Whale Optimization Algorithm " *Advances in Engineering Software*, vol. 95, pp. 51-67, 2016.
- [٢٣] A. O. Topal and O. Altun, "A novel meta-heuristic algorithm: Dynamic Virtual Bats Algorithm," *Information Sciences*, vol. 354, pp. 222-235, 2016.

- [۲۴] B. Meryem and B. Abdelmadjid, "Quantum Inspired Algorithm for a VRP with Heterogeneous Fleet Mixed Backhauls and Time Windows," *International Journal of Applied Metaheuristic Computing (IJAMC)*, vol. 7, no. 4, pp. 18-38, 2016.
- [۲۵] S. Mirjalili, A. Gandomi, S. Z. Mirjalili, S. Saremi, H. Faris, and S. Mirjalili, "Salp Swarm Algorithm: A bio-inspired optimizer for engineering design problems," *Advances in Engineering Software*, vol. 114, pp. 163-191, 2017.
- [۲۶] S. Saremi, S. Mirjalili, and A. Lewis, "Grasshopper Optimisation Algorithm: Theory and application," *Advances in Engineering Software*, vol. 105, pp. 30-47, 2017.
- [۲۷] S. Mirjalili, "The Ant Lion Optimizer," *Advances in Engineering Software*, vol. 83, pp. 80-98, 2015.
- [۲۸] A. Kaveh and N. Farhoudi, "A new optimization method: Dolphin echolocation," *Advances in Engineering Software*, vol. 59, pp. 53-70, 2013.
- [۲۹] M. Gong, S. Wang, W. Liu, J. Yan, and L. Jiao, "Evolutionary computation in China: A literature survey," *CAAI Transactions on Intelligence Technology*, vol. 1, no. 4, pp. 334-354, 2016.
- [۳۰] T. Joyce and J. M. Herrmann, "A Review of No Free Lunch Theorems, and Their Implications for Metaheuristic Optimisation," in *Nature-Inspired Algorithms and Applied Optimization*, X.-S. Yang, Ed. Cham: Springer International Publishing, 2018, pp. 27-51.
- [۳۱] G. Rizzolatti and M. Fabbri-Destro, "Mirror neurons: from discovery to autism," *Experimental Brain Research*, journal article vol. 200, no. 3, pp. 223-237, 2010.
- [۳۲] S. Lacoste-Badie and O. Droulers, *Advertising Memory: The Power of Mirror Neurons*. 2014, pp. 195-202.
- [۳۳] G. G. Wang, S. Deb, and L. d. S. Coelho, "Elephant Herding Optimization," in *2015 3rd International Symposium on Computational and Business Intelligence (ISCBI)*, 2015, pp. 1-5.
- [۳۴] S. Mirjalili, "Moth-flame optimization algorithm: A novel nature-inspired heuristic paradigm," *Knowledge-Based Systems*, vol. 89, pp. 228-249, 2015.
- [۳۵] R. Zhao and W. Tang, *Monkey algorithm for global numerical optimization*. 2008, pp. 165-176.
- [۳۶] B. Javidy, A. Hatamlou, and S. Mirjalili, "Ions motion algorithm for solving optimization problems," *Applied Soft Computing*, vol. 32, pp. 72-79, 2015.
- [۳۷] H. Salimi, "Stochastic Fractal Search: A powerful metaheuristic algorithm," *Knowledge-Based Systems*, vol. 75, pp. 1-18, 2015.
- [۳۸] A. Husseinzadeh Kashan, "A new metaheuristic for optimization: Optics inspired optimization (OIO)," *Computers & Operations Research*, vol. 55, pp. 99-125, 2015.
- [۳۹] A. Husseinzadeh Kashan, "League Championship Algorithm (LCA): An algorithm for global optimization inspired by sport championships," *Applied Soft Computing*, vol. 16, pp. 171-200, 2014.
- [۴۰] Z. Bayraktar, M. Komurcu, and D. H. Werner, "Wind Driven Optimization (WDO): A novel nature-inspired optimization algorithm and its application to electromagnetics," in *2010 IEEE Antennas and Propagation Society International Symposium*, 2010, pp. 1-4.
- [۴۱] X. Z. Gao, V. Govindasamy, H. Xu, X. Wang, and K. Zenger, "Harmony Search Method: Theory and Applications," *Computational Intelligence and Neuroscience*, vol. 2015, p. 10, 2015, Art. no. 258491.
- [۴۲] I. Fister, I. Fister, X.-S. Yang, and J. Brest, "A comprehensive review of firefly algorithms," *Swarm and Evolutionary Computation*, vol. 13, pp. 34-46, 2013.
- [۴۳] D. Simon, "Biogeography-Based Optimization," *IEEE Transactions on Evolutionary Computation*, vol. 12, no. 6, pp. 702-713, 2008.
- [۴۴] X.-S. Yang, "A New Metaheuristic Bat-Inspired Algorithm," in *Nature Inspired Cooperative Strategies for Optimization (NICSO 2010)*, J. R. González, D. A. Pelta, C. Cruz, G. Terrazas, and N. Krasnogor, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2010, pp. 65-74.

- [۴۵] R. V. Rao, V. J. Savsani, and D. P. Vakharia, "Teaching–learning-based optimization: A novel method for constrained mechanical design optimization problems," *Computer-Aided Design*, vol. 43, no. ۳, pp. 303-315, 2011.
- [۴۶] R. V. Rao and V. Patel, "An improved teaching-learning-based optimization algorithm for solving unconstrained optimization problems," *Scientia Iranica*, vol. 20, no. 3, pp. 710-720, 2013.
- [۴۷] A. H. Gandomi, X.-S. Yang, and A. H. Alavi, "Cuckoo search algorithm: a metaheuristic approach to solve structural optimization problems," *Engineering with Computers*, journal article vol. 29, no. 1, pp. 17-35, 2013.
- [۴۸] C. H. and G. H. C., "STRUCTURAL OPTIMIZATION USING A NEW LOCAL APPROXIMATION METHOD," *International Journal for Numerical Methods in Engineering*, vol. 39, no. 5, pp. 829-846, 1996.
- [۴۹] A. Kaveh and S. Talatahari, "Optimal design of skeletal structures via the charged system search algorithm," *Structural and Multidisciplinary Optimization*, journal article vol. 41, no. 6, pp. 893-911, 2010.
- [۵۰] H. Liu, Z. Cai, and Y. Wang, "Hybridizing particle swarm optimization with differential evolution for constrained numerical and engineering optimization," *Applied Soft Computing*, vol. 10, no. 2, pp. 629-640, 2010.
- [۵۱] H. Shah-Hosseini, *Principal components analysis by the galaxy-based search algorithm: A novel metaheuristic for continuous optimisation*. 2011, pp. 132-140.
- [۵۲] K. A. and T. S., "An improved ant colony optimization for constrained engineering design problems," *Engineering Computations*, vol. 27, no. 1, pp. 155-182, 2010.
- [۵۳] F.-z. Huang, L. Wang, and Q. He, "An effective co-evolutionary differential evolution for constrained optimization," *Applied Mathematics and Computation*, vol. 186, no. 1, pp. 340-356, 2007.
- [۵۴] E. Mezura-Montes and C. A. C. Coello, "An empirical study about the usefulness of evolution strategies to solve constrained optimization problems," *International Journal of General Systems*, vol. 37, no. 4, pp. 443-473, 2008.
- [۵۵] K. Deb, "GeneAS: A Robust Optimal Design Technique for Mechanical Component Design," in *Evolutionary Algorithms in Engineering Applications*, D. Dasgupta and Z. Michalewicz, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 1997, pp. 497-514.
- [۵۶] C. A. Coello Coello and E. Mezura Montes, "Constraint-handling in genetic algorithms through the use of dominance-based tournament selection," *Advanced Engineering Informatics*, vol. 16, no. 3, pp. 193-203, 2002.
- [۵۷] C. A. Coello Coello, "Use of a self-adaptive penalty approach for engineering optimization problems," *Computers in Industry*, vol. 41, no. 2, pp. 113-127, 2000.
- [۵۸] Q. He and L. Wang, "An effective co-evolutionary particle swarm optimization for constrained engineering design problems," *Engineering Applications of Artificial Intelligence*, vol. 20, no. 1, pp. 89-99, 2007.
- [۵۹] M. Mahdavi, M. Fesanghary, and E. Damangir, "An improved harmony search algorithm for solving optimization problems," *Applied Mathematics and Computation*, vol. 188, no. 2, pp. 1567-1579, 2007.
- [۶۰] B. K. Kannan and S. N. Kramer, "An Augmented Lagrange Multiplier Based Method for Mixed Integer Discrete Continuous Optimization and Its Applications to Mechanical Design," *Journal of Mechanical Design*, vol. ۱۱۶, no. 2, pp. 405-411, 1994.
- [۶۱] E. Sandgren, "Nonlinear Integer and Discrete Programming in Mechanical Design Optimization," *Journal of Mechanical Design*, vol. 112, no. 2, pp. 223-229, 1990.